

Análisis de datos I

¿Qué puede hacer Pandas?

Indicar si:

- ¿Existe correlación entre dos o más columnas?
- ¿Cuál es el valor promedio?
- ¿El valor máximo?
- ¿El valor mínimo?

Pandas también puede eliminar filas irrelevantes o que contengan valores erróneos, como valores vacíos o nulos. Esto se conoce como limpieza de datos.

Primeros pasos con los pandas

Instalación de Pandas



```
pip install pandas
```

Importar pandas



```
import pandas
```

Serie de Pandas

Una serie de Pandas es como una columna en una tabla. Es una matriz unidimensional que almacena datos de cualquier tipo.

Si no se especifica nada, los valores se etiquetan con su índice. Esta etiqueta se puede usar para acceder a un valor específico.

Crea una serie simple de Pandas a partir de una lista

```
import pandas as pd

a = [1, 7, 2]

myvar = pd.Series(a)

print(myvar)

print(myvar[0])
```

0	1
1	7
2	2

```
1
```

Con el argumento de índice, puedes nombrar tus propias etiquetas.

```
import pandas as pd

a = [1, 7, 2]

myvar = pd.Series(a, index = ["x", "y", "z"])

print(myvar)

print(myvar["y"])
```

También puedes utilizar un objeto como un diccionario, al crear una Serie.

```
import pandas as pd

calories = {"day1": 420, "day2": 380, "day3": 390}

myvar = pd.Series(calories)

print(myvar)
```

DataFrames

Un DataFrame de Pandas es una estructura de datos bidimensional, como una matriz bidimensional o una tabla con filas y columnas.

Una Serie es como una columna, mientras que un DataFrame es la tabla completa.

```
import pandas as pd

data = {
    "calories": [420, 380, 390],
    "duration": [50, 40, 45]
}

#load data into a DataFrame object:
df = pd.DataFrame(data)
print(df)
```

	calories	duration
0	420	50
1	380	40
2	390	45

Localizar fila

Como se puede observar en el resultado anterior, el DataFrame se comporta como una tabla con filas y columnas. Pandas utiliza el atributo **loc** para devolver una o más filas específicas.

```
print(df.loc[0])
```

Índices con nombre

Con el argumento **index**, puedes definir tus propios índices. Utiliza el índice especificado en el atributo **loc** para obtener la(s) fila(s) indicada(s).

```
import pandas as pd
data = {
    "calories": [420, 380, 390],
    "duration": [50, 40, 45]
}
df = pd.DataFrame(
    data,
    index = ["day1", "day2", "day3"]
)
print(df.loc["day2"])
```

Leer archivos

Leer CSV

```
import pandas as pd

df = pd.read_csv('data.csv')

print(df)
```

Leer JSON

```
import pandas as pd

df = pd.read_json('data.json')

print(df)
```

Visualización de los datos

Head

El método `head()` devuelve los encabezados y un número específico de filas, comenzando desde la parte superior.

```
import pandas as pd

df = pd.read_csv('data.csv')

print(df.head(10))
```

Tail

El método `tail()` devuelve los encabezados y un número específico de filas, comenzando desde la parte inferior.

```
import pandas as pd

df = pd.read_csv('data.csv')

print(df.tail(10))
```

Información sobre los datos

El objeto **DataFrames** tiene un método llamado **info()**, que proporciona más información sobre el conjunto de datos.

El resultado nos indica que hay 169 filas y 4 columnas, el nombre de cada columna, con el tipo de datos y cuántos valores no nulos hay en cada columna.

```
RangeIndex: 169 entries, 0 to 168
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Duration    169 non-null    int64
1   Pulse       169 non-null    int64
2   Maxpulse    169 non-null    int64
3   Calories    164 non-null    float64
dtypes: float64(1), int64(3)
memory usage: 5.4 KB
None
```

Max

El método **max()** devuelve el máximo de una o varias columnas.

```
import pandas as pd

df = pd.read_csv('data.csv')

print(datos['edad'].max())
```

Min

El método **min()** devuelve el mínimo de una o varias columnas.

```
import pandas as pd

df = pd.read_csv('data.csv')

print(datos['edad'].min())
```

Actividad 3: Análisis de datos con Pandas

En esta actividad utilizará la biblioteca Pandas para crear y analizar un conjunto de datos (dataset) generado por la misma clase.

Requisitos:

- Utilice Microsoft Excel para crear un archivo CSV llamado **estudiantes.csv**.
- El archivo debe contener las siguientes columnas:
 - Nombre
 - Edad
 - Estatura
- Para completar el archivo, recolecte la información de los estudiantes presentes en el aula.
- Guarde el archivo en formato CSV (delimitado por comas).

Una vez creado el archivo, desarrolle un programa en Python utilizando Pandas que realice lo siguiente:

- Cargue el archivo **estudiantes.csv**.
- Muestre el contenido completo del dataset.
- Indique la persona con mayor edad.
- Indique la persona con menor edad.
- Indique la persona con mayor estatura.
- Indique la persona con menor estatura.