

Análisis de datos II

BACH. DANIEL PÉREZ MORERA

Limpieza de datos

La limpieza de datos consiste en corregir los datos erróneos de tu conjunto de datos.

Los datos erróneos pueden ser:

Celdas vacías

Datos con formato incorrecto

Datos erróneos

Duplicados

¿Cómo eliminar celdas vacías?

Una forma de lidiar con las celdas vacías es eliminar las filas que las contienen.

```
import pandas as pd

df = pd.read_csv('data.csv')

new_df = df.dropna()

print(new_df.to_string())

print(new_df.to_csv())
```

¿Cómo reemplazar valores vacíos?

Otra forma de lidiar con las celdas vacías es insertar un nuevo valor.

```
import pandas as pd

df = pd.read_csv('data.csv')

df.fillna(130, inplace = True)
```

¿Cómo reemplazar solo para las columnas especificadas?

Para reemplazar únicamente los valores vacíos de una columna, especifique el nombre de la columna para el DataFrame.



```
import pandas as pd

df = pd.read_csv('data.csv')

df.fillna({"Calories": 130}, inplace=True)
```

¿Cómo reemplazar usando la media, mediana o moda

Una forma común de reemplazar las celdas vacías es calcular la media, la mediana o la moda de la columna.

Pandas utiliza los métodos *mean()*, *median()* y *mode()* para calcular los valores respectivos de una columna específica:

Reemplazar usando la media, mediana o moda



```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mean()

df.fillna({"Calories": x}, inplace=True)
```

```
df.fillna({"Calories": x}, inplace=True)
```

```
x = df["Calories"].median()
```



```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].median()

df.fillna({"Calories": x}, inplace=True)
```

```
df.fillna({"Calories": x}, inplace=True)
```

```
x = df["Calories"].mode().values[0]
```

Reemplazar usando la media, mediana o moda



```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mode()[0]

df.fillna({"Calories": x}, inplace=True)

df.fillna({"Calories": x}, inplace=True)
```

Python 3.7.4 Shell [~/Desktop/Python/1/1/1]

¿Cómo limpiar datos con formato incorrecto?

Las celdas con datos en formato incorrecto pueden dificultar, o incluso imposibilitar, el análisis de los datos.

Para solucionarlo, tienes dos opciones: eliminar las filas o convertir todas las celdas de las columnas al mismo formato.

¿Cómo limpiar datos con formato incorrecto?



```
import pandas as pd

df = pd.read_csv('data.csv')

df['Date'] = pd.to_datetime(df['Date'], format='mixed')

print(df.to_string())
```

```
print(df.to_string())
```



```
import pandas as pd

df = pd.read_csv('data.csv')

df.dropna(subset=['Date'], inplace = True)
```

```
df.dropna(subset=['Date'], inplace = True)
```

¿Cómo corregir datos erróneos?

Los "datos erróneos" no tienen por qué ser "celdas vacías" o "formato incorrecto", simplemente pueden ser incorrectos, como si alguien hubiera registrado "199" en lugar de "1,99".

A veces, al observar el conjunto de datos, se pueden detectar datos erróneos, ya que se tiene una expectativa sobre cómo deberían ser.

¿Cómo corregir datos erróneos?

REEMPLAZAR VALORES

```
import pandas as pd

df = pd.read_csv('data.csv')

for x in df.index:
    if df.loc[x, "Duration"] > 120:
        df.loc[x, "Duration"] = 120
```

```
df.loc[x, "Duration"] = 120
if df.loc[x, "Duration"] > 120:
```

ELIMINAR FILAS

```
import pandas as pd

df = pd.read_csv('data.csv')

for x in df.index:
    if df.loc[x, "Duration"] > 120:
        df.drop(x, inplace = True)
```

```
df.drop(x, inplace = True)
if df.loc[x, "Duration"] > 120:
```

Correlaciones de datos

El método **corr()** calcula la relación entre cada columna de tu conjunto de datos.

El resultado del método **corr()** es una tabla con muchos números que representan la relación entre dos columnas.

Correlaciones de datos



```
import pandas as pd

df = pd.read_csv('data.csv')

df.corr()
```


```
qt.corr()
```



	Duration	Pulse	Maxpulse	Calories
Duration	1.000000	-0.155408	0.009403	0.922721
Pulse	-0.155408	1.000000	0.786535	0.025120
Maxpulse	0.009403	0.786535	1.000000	0.203814
Calories	0.922721	0.025120	0.203814	1.000000

qt.corr()

Correlaciones de datos



Graficación

Pandas utiliza el método **plot()** para crear diagramas.

Podemos usar Pyplot, un submódulo de la biblioteca Matplotlib, para visualizar el diagrama en pantalla.

Graficación

INSTALACIÓN DE MATPLOTLIB



```
pip install matplotlib
```

```
brb_rus29rr w9rbroerrp
```

IMPORTAR MATPLOTLIB



```
import matplotlib.pyplot as plt
```

```
rwbolr w9rbroerrp·bλbrof 92 brf
```

Graficación

Especifica que deseas un diagrama de dispersión con el argumento **kind**.

Tipos de diagramas:

Histograma(hist)
Gráficos de líneas (plot)
Diagrama de dispersion(scatter)
Gráficos de barras (bar y barh)

Graficación

Algunos diagramas requieren un eje x y un eje y.

En el siguiente ejemplo, usaremos "Duración" para el eje x y "Calorías" para el eje y.



```
import pandas as pd
import matplotlib.pyplot as plt

df = pd.read_csv('data.csv')

df.plot(kind = 'scatter',
        x = 'Duration', y = 'Calories')

plt.show()
```

```
plt.show()
```

```
x = 'Duration', y = 'Calories')
```

¿Cómo convertir objetos en un DataFrame?

```
import pandas as pd

class Persona:
    def __init__(self, nombre, edad):
        self.nombre = nombre
        self.edad = edad

personas = [
    Persona("Ana", 20),
    Persona("Juan", 25)]

datos = []

for persona in personas:
    datos.append(persona.__dict__)

df = pd.DataFrame(datos)
```

Actividad 4: Limpieza de datos con Pandas

Utilice el archivo `estudiantes.csv` y Pandas para limpiar y analizar los datos.

Pasos:

- Cargar el dataset

- Cargue el archivo utilizando Pandas.
- Muestre el contenido.

- Limpiar los datos

- Elimine los registros duplicados.

Identifique los valores vacíos y reemplácelos utilizando la media de la columna.

Corrija los datos que tengan un formato incorrecto o que sean evidentemente erróneos.

- Analizar los datos

- Calcule el promedio de Edad, Peso, HorasEstudio y Calificación.

- Calcular correlaciones

- Utilice `corr()` para obtener la matriz de correlación.
- Analice las siguientes relaciones:

- HorasEstudio y Calificación
- Estatura y Peso

- Graficación

- Haga un grafico de líneas para las columnas estatura y peso.