

Análisis de datos II

Limpieza de datos

La limpieza de datos consiste en corregir los datos erróneos de tu conjunto de datos.

Los datos erróneos pueden ser:

- Celdas vacías
- Datos con formato incorrecto
- Datos erróneos
- Duplicados

¿Cómo eliminar celdas vacías?

Una forma de lidiar con las celdas vacías es eliminar las filas que las contienen.

```
import pandas as pd

df = pd.read_csv('data.csv')

new_df = df.dropna()

print(new_df.to_string())
```

¿Cómo reemplazar valores vacíos?

Otra forma de lidiar con las celdas vacías es insertar un nuevo valor.

```
import pandas as pd

df = pd.read_csv('data.csv')

df.fillna(130, inplace = True)
```

¿Cómo reemplazar solo para las columnas especificadas?

Para reemplazar únicamente los valores vacíos de una columna, especifique el nombre de la columna para el DataFrame.

```
import pandas as pd

df = pd.read_csv('data.csv')

df.fillna({"Calories": 130}, inplace=True)
```

¿Cómo reemplazar usando la media, mediana o moda?

Una forma común de reemplazar las celdas vacías es calcular la media, la mediana o la moda de la columna.

Pandas utiliza los métodos `mean()`, `median()` y `mode()` para calcular los valores respectivos de una columna específica:

```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mean()

df.fillna({"Calories": x}, inplace=True)
```

```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].median()

df.fillna({"Calories": x}, inplace=True)
```

```
import pandas as pd

df = pd.read_csv('data.csv')

x = df["Calories"].mode()[0]

df.fillna({"Calories": x}, inplace=True)
```

¿Cómo limpiar datos con formato incorrecto?

Las celdas con datos en formato incorrecto pueden dificultar, o incluso imposibilitar, el análisis de los datos.

Para solucionarlo, tienes dos opciones: eliminar las filas o convertir todas las celdas de las columnas al mismo formato.

```
import pandas as pd

df = pd.read_csv('data.csv')

df['Date'] = pd.to_datetime(df['Date'], format='mixed')

print(df.to_string())
```

```
import pandas as pd

df = pd.read_csv('data.csv')

df.dropna(subset=['Date'], inplace = True)
```

¿Cómo corregir datos erróneos?

Los "datos erróneos" no tienen por qué ser "celdas vacías" o "formato incorrecto", simplemente pueden ser incorrectos, como si alguien hubiera registrado "199" en lugar de "1,99".

A veces, al observar el conjunto de datos, se pueden detectar datos erróneos, ya que se tiene una expectativa sobre cómo deberían ser.

Reemplazar valores

```
import pandas as pd

df = pd.read_csv('data.csv')

for x in df.index:
    if df.loc[x, "Duration"] > 120:
        df.loc[x, "Duration"] = 120
```

Eliminar filas

```
import pandas as pd

df = pd.read_csv('data.csv')

for x in df.index:
    if df.loc[x, "Duration"] > 120:
        df.drop(x, inplace = True)
```

Correlaciones de datos

El método `corr()` calcula la relación entre cada columna de tu conjunto de datos.


El resultado del método `corr()` es una tabla con muchos números que representan la relación entre dos columnas.

```
import pandas as pd

df = pd.read_csv('data.csv')

df.corr()
```

	Duration	Pulse	Maxpulse	Calories
Duration	1.000000	-0.155408	0.009403	0.922721
Pulse	-0.155408	1.000000	0.786535	0.025120
Maxpulse	0.009403	0.786535	1.000000	0.203814
Calories	0.922721	0.025120	0.203814	1.000000



Graficación

Pandas utiliza el método `plot()` para crear diagramas. Podemos usar `Pyplot`, un submódulo de la biblioteca `Matplotlib`, para visualizar el diagrama en pantalla.

Instalación de Matplotlib

```
● ● ●  
pip install matplotlib
```

Importar Matplotlib

```
● ● ●  
import matplotlib.pyplot as plt
```

Especifica que deseas un diagrama de dispersión con el argumento **kind**.

Tipos de diagramas:

- Histograma(`hist`)
- Gráficos de líneas (`plot`)
- Diagrama de dispersión(`scatter`)
- Gráficos de barras (`bar` y `barh`)

Algunos diagramas requieren un eje x y un eje y. En el siguiente ejemplo, usaremos "Duración" para el eje x y "Calorías" para el eje y.

```
● ● ●  
  
import pandas as pd  
import matplotlib.pyplot as plt  
  
df = pd.read_csv('data.csv')  
  
df.plot(kind = 'scatter',  
        x = 'Duration', y = 'Calories')  
  
plt.show()
```

Actividad 4: Limpieza de datos con Pandas

Utilice el archivo `estudiantes.csv` y `Pandas` para limpiar y analizar los datos.

Pasos:

- Cargar el dataset
 - Cargue el archivo utilizando `Pandas`.
 - Muestre el contenido.
- Limpiar los datos
 - Elimine los registros duplicados.
 - Identifique los valores vacíos y reemplácelos utilizando la media de la columna.
 - Corrija los datos que tengan un formato incorrecto o que sean evidentemente erróneos.
- Analizar los datos
 - Calcule el promedio de Edad, Peso, HorasEstudio y Calificación.
- Calcular correlaciones
 - Utilice `corr()` para obtener la matriz de correlación.
 - Analice las siguientes relaciones:
 - HorasEstudio y Calificación
 - Estatura y Peso
- Graficación
 - Haga un gráfico de líneas para las columnas estatura y peso.